

Московский физико-технический институт
(национальный исследовательский университет)
Факультет биологической и медицинской физики

Домашнее задание 7

Построение и анализ филогенетических деревьев белка
Actin beta

Выполнила:
Шифон Анна
Группа Б06-302

Долгопрудный, 2026

1 Задание 1. Подготовка данных

1.1 Выбор гена и получение ортологов

В качестве изучаемого гена был выбран **АКТВ** (*actin beta*, *Homo sapiens*). Бета-актин — один из наиболее консервативных и повсеместно экспрессируемых белков у эукариот, что делает его удобным объектом для анализа эволюционных взаимоотношений у млекопитающих.

Ортологи были получены через базу данных **NCBI**. Во вкладке *Orthologs* был применён фильтр по таксону **Mammalia**. Для построения деревьев было отобрано **100 белковых последовательностей** из 251 доступного ортолога (согласно рекомендации в условии задания). Длина белка во всех таксонах составляет 375 а.к.

ACTB - actin beta **BETA**
Homo sapiens

Summary Transcripts and proteins **Orthologs** Gene ontology

Orthologs

Method: NCBI Ortholog ⓘ

Selected taxa
Mammalia ⓘ Enter one or more taxonomic names

Download ▾ Align ▾ Select columns 251 Genes 251 selected Rows per page 20 ▾ 1-20 of 251 < >

☒	Scientific name	Symbol	Chromosome	Isoforms	Protein accession	Length (aa)	Architecture	Action
☒	Homo sapiens (human)	ACTB	7	1	NP_001092.1	375		⋮
☒	Mus musculus (house mouse)	Actb	5	1	NP_031419.1	375		⋮
☒	Rattus norvegicus (Norway rat)	Actb	12	1	NP_112406.1	375		⋮
☒	Bos taurus (domestic cattle)	ACTB	25	1	NP_776404.2	375		⋮
☒	Canis lupus familiaris (dog)	ACTB	6	1	NP_001182774.2	375		⋮
☒	Sus scrofa (pig)	ACTB	3	3	NP_001431349.1	375		⋮
☒	Pan troglodytes (chimpanzee)	ACTB	6	1	NP_001009945.1	375		⋮
☒	Macaca mulatta (Rhesus monkey)	ACTB	3	1	NP_001028256.1	375		⋮
☒	Oryctolagus cuniculus (rabbit)	ACTB	19	1	NP_001095153.1	375		⋮
☒	Equus caballus (horse)	ACTB	13	2	NP_001075307.1	375		⋮

3k_fbm_f_sukhanov_kvan

Рис. 1: Список ортологов АКТВ у Mammalia в базе данных NCBI Gene. Показаны первые 10 записей; всего доступно 251 последовательность. Метод определения ортологов — NCBI Ortholog. Длина белка — 375 а.к. во всех таксонах.

1.2 Переименование заголовков FASTA

Заголовки в FASTA-файле были переименованы из стандартного с помощью следующего скрипта на Python:

```
1 from Bio import SeqIO
2 import re
3
4 input_file = "actb_raw.faa"
5 output_file = "actb_renamed.fasta"
6
7 count = 0
8
9 with open(output_file, "w") as out:
10     for record in SeqIO.parse(input_file, "fasta"):
11         desc = record.description
12
13         match = re.search(r'\[organism=([^\]]+)\]', desc)
14         if match:
15             organism = match.group(1).strip().replace(" ",
16                 "_").replace(".", "").replace("(", "").replace(")",
17                 "")
18
19             accession = record.id.split('.')[0]
20
21             new_id = f"{organism}_{accession}"
22
23             record.id = new_id
24             record.description = ""
25
26             SeqIO.write(record, out, "fasta")
27             count += 1
```

Результат преобразования:

- Было: >NP_001092.1 ACTB [organism=Homo sapiens] [GeneID=60]
- Стало: >Homo_sapiens_NP_001092

2 Задание 2. Множественное выравнивание (MSA)

Множественное выравнивание 100 белковых последовательностей АСТВ было выполнено в программе **MEGA** с использованием алгоритма **MUSCLE** со стандартными параметрами.



Рис. 2: Результат выравнивания MUSCLE

3 Задание 3. Построение филогенетических деревьев

3.1 Выбор лучшей модели молекулярной эволюции

Для выбора оптимальной модели молекулярной эволюции был использован *Best-Fit Substitution Model*. Результаты ранжирования по критерию BIC:

M Results

Table. Maximum Likelihood analysis of substitution models

Model	Parameters	BIC	AICc	lnL	(+I)	(+G)	f(A)	f(R)	f(N)	f(D)	f(C)	f(Q)	f(E)	f(G)	f(H)	f(I)	f(L)	f(K)	f(M)	f(F)	f(P)	f(S)
WAG+I	198	6609.748	4926.266	-2264.057	0.54	n/a	0.087	0.044	0.039	0.057	0.019	0.037	0.058	0.083	0.024	0.048	0.086	0.062	0.020	0.038	0.046	0.070
WAG+G+I	199	6617.190	4925.217	-2262.521	0.54	1.72	0.087	0.044	0.039	0.057	0.019	0.037	0.058	0.083	0.024	0.048	0.086	0.062	0.020	0.038	0.046	0.070
JTT+I	198	6650.621	4967.139	-2284.493	0.54	n/a	0.077	0.051	0.043	0.051	0.020	0.041	0.062	0.075	0.023	0.053	0.091	0.060	0.023	0.041	0.051	0.068
LG+I	198	6653.923	4970.441	-2286.144	0.54	n/a	0.079	0.056	0.042	0.053	0.013	0.041	0.072	0.057	0.022	0.062	0.099	0.065	0.023	0.042	0.044	0.061
JTT+G+I	199	6655.516	4963.542	-2281.684	0.54	1.19	0.077	0.051	0.043	0.051	0.020	0.041	0.062	0.075	0.023	0.053	0.091	0.060	0.023	0.041	0.051	0.068
LG+G+I	199	6660.372	4968.398	-2284.112	0.54	1.44	0.079	0.056	0.042	0.053	0.013	0.041	0.072	0.057	0.022	0.062	0.099	0.065	0.023	0.042	0.044	0.061
cpREV+I	198	6670.955	4987.473	-2294.660	0.54	n/a	0.076	0.062	0.041	0.037	0.009	0.038	0.050	0.084	0.025	0.081	0.101	0.050	0.022	0.051	0.043	0.062
cpREV+G+I	199	6676.559	4984.586	-2292.206	0.54	1.36	0.076	0.062	0.041	0.037	0.009	0.038	0.050	0.084	0.025	0.081	0.101	0.050	0.022	0.051	0.043	0.062
Dayhoff+G+I	199	6687.556	4995.583	-2297.704	0.54	1.15	0.087	0.041	0.040	0.047	0.034	0.038	0.050	0.089	0.034	0.037	0.085	0.081	0.015	0.040	0.051	0.070
Dayhoff+I	198	6688.788	5005.306	-2303.577	0.54	n/a	0.087	0.041	0.040	0.047	0.034	0.038	0.050	0.089	0.034	0.037	0.085	0.081	0.015	0.040	0.051	0.070
rtREV+I	198	6738.374	5054.892	-2328.369	0.54	n/a	0.065	0.045	0.038	0.042	0.011	0.061	0.061	0.064	0.027	0.068	0.102	0.075	0.015	0.029	0.068	0.049
rtREV+G+I	199	6745.314	5053.340	-2326.583	0.54	1.60	0.065	0.045	0.038	0.042	0.011	0.061	0.061	0.064	0.027	0.068	0.102	0.075	0.015	0.029	0.068	0.049
Poisson+I+F	217	6789.249	4944.448	-2253.931	0.54	n/a	0.079	0.049	0.024	0.061	0.016	0.032	0.069	0.075	0.024	0.075	0.073	0.051	0.046	0.035	0.052	0.068
Poisson+I	198	6793.805	5110.323	-2356.085	0.54	n/a	0.050	0.050	0.050	0.050	0.050	0.050	0.050	0.050	0.050	0.050	0.050	0.050	0.050	0.050	0.050	0.050
Poisson+G+I+F	218	6799.905	4946.614	-2254.002	0.54	200.00	0.079	0.049	0.024	0.061	0.016	0.032	0.069	0.075	0.024	0.075	0.073	0.051	0.046	0.035	0.052	0.068
mtREV24+G+I	199	6801.379	5109.405	-2354.615	0.54	1.00	0.072	0.019	0.039	0.019	0.006	0.025	0.024	0.056	0.028	0.087	0.168	0.023	0.053	0.060	0.055	0.072
WAG+I+F	217	6804.118	4959.316	-2261.365	0.54	n/a	0.079	0.049	0.024	0.061	0.016	0.032	0.069	0.075	0.024	0.075	0.073	0.051	0.046	0.035	0.052	0.068
Poisson+G+I	199	6804.317	5112.343	-2356.084	0.54	115.88	0.050	0.050	0.050	0.050	0.050	0.050	0.050	0.050	0.050	0.050	0.050	0.050	0.050	0.050	0.050	0.050
mtREV24+I	198	6807.402	5123.920	-2362.883	0.54	n/a	0.072	0.019	0.039	0.019	0.006	0.025	0.024	0.056	0.028	0.087	0.168	0.023	0.053	0.060	0.055	0.072
WAG+G+I+F	218	6811.634	4958.343	-2259.867	0.54	1.69	0.079	0.049	0.024	0.061	0.016	0.032	0.069	0.075	0.024	0.075	0.073	0.051	0.046	0.035	0.052	0.068
LG+I+F	217	6816.733	4971.931	-2267.673	0.54	n/a	0.079	0.049	0.024	0.061	0.016	0.032	0.069	0.075	0.024	0.075	0.073	0.051	0.046	0.035	0.052	0.068
rtREV+I+F	217	6818.357	4973.556	-2268.485	0.54	n/a	0.079	0.049	0.024	0.061	0.016	0.032	0.069	0.075	0.024	0.075	0.073	0.051	0.046	0.035	0.052	0.068
cpREV+I+F	217	6821.818	4977.017	-2270.215	0.54	n/a	0.079	0.049	0.024	0.061	0.016	0.032	0.069	0.075	0.024	0.075	0.073	0.051	0.046	0.035	0.052	0.068
JTT+I+F	217	6822.171	4977.370	-2270.392	0.54	n/a	0.079	0.049	0.024	0.061	0.016	0.032	0.069	0.075	0.024	0.075	0.073	0.051	0.046	0.035	0.052	0.068

Рис. 3: Результаты выбора лучшей модели молекулярной эволюции.

По критерию **BIC** наилучшей моделью является **WAG+I**. Далее она используется для построения ML-дерева.

3.2 ML-дерево (Maximum Likelihood, WAG+I, bootstrap = 100)




Рис. 4: Филогенетическое дерево максимального правдоподобия (ML), модель WAG+I, bootstrap = 100. Верхняя часть.




Рис. 5: Филогенетическое дерево максимального правдоподобия (ML), модель WAG+I, bootstrap = 100. Средняя часть.



Рис. 6: Филогенетическое дерево максимального правдоподобия (ML), модель WAG+I, bootstrap = 100. Нижняя часть.

3.3 NJ-дерево (Neighbor-Joining, bootstrap = 100)




Рис. 7: Филогенетическое дерево методом ближайшего соседа (NJ), bootstrap = 100. Верхняя часть.




Рис. 8: Филогенетическое дерево методом ближайшего соседа (NJ), bootstrap = 100. Средняя часть.




Рис. 9: Филогенетическое дерево методом ближайшего соседа (NJ), bootstrap = 100. Нижняя часть.

3.4 UPGMA-дерево (bootstrap = 100)




Рис. 10: Филогенетическое дерево методом UPGMA, bootstrap = 100. Верхняя часть.




Рис. 11: Филогенетическое дерево методом UPGMA, bootstrap = 100. Средняя часть.




Рис. 12: Филогенетическое дерево методом UPGMA, bootstrap = 100. Нижняя часть.

4 Задание 4. Анализ и сравнение результатов

4.1 Сравнение по bootstrap

Проанализируем значения bootstrap, которые видны на скриншотах деревьев.

ML-дерево (WAG+I): Большинство внутренних узлов имеют низкие значения (50–60). Высокие значения (99) встречаются только в отдельных хорошо разрешённых кластерах. Это означает, что глобальная топология дерева статистически не очень уверенная, хотя отдельные группы поддержаны хорошо.

NJ-дерево: Картина похожая: есть несколько узлов с высокой поддержкой (92, 99), но многие узлы имеют низкие значения (50–57).

UPGMA-дерево: Характерная особенность — очень много узлов ровно с bootstrap = 60. Это подозрительно однородно и говорит о том, что UPGMA в данном случае строит дерево с искусственно похожими, невысокими значениями поддержки.

Вывод по bootstrap: Ни одно дерево не демонстрирует стабильно высокой поддержки всех узлов. ML-дерево является наиболее методологически обоснованным, так как использует статистически лучшую модель (WAG+I). NJ даёт сопоставимые результаты. UPGMA показывает наихудшее качество.

4.2 Сравнение по биологичности топологии

Ожидаемая топология правильного дерева млекопитающих:

- **Приматы** (*Homo sapiens*, *Pan troglodytes*, *Macaca*, *Gorilla*, *Papio*, *Mandrillus*, *Theropithecus*) должны быть в одном кластере.
- **Грызуны** (*Mus*, *Rattus*, *Cricetulus*, *Mesocricetus*, *Arvicola*, *Myodes* и др.) — в одном кластере (Rodentia).
- **Непарнокопытные** (*Equus* — лошадь, осёл, зебра) должны держаться вместе.
- **Парнокопытные** (*Bos*, *Sus*, *Ovis*, *Capra*, *Cervus*) — вместе.
- **Китообразные** (*Phocoena*, *Orcinus*, *Delphinapterus*) — вместе.
- **Рукокрылые** (*Myotis*, *Pteropus*, *Rhinolophus*, *Hipposideros*) — вместе.
- **Хищные (Carnivora)** (*Canis*, *Felis*, *Mustela*) — вместе.

ML-дерево: Смешанная картина. Некоторые ожидаемые группы частично держатся вместе (например, виды *Equus* встречаются рядом, несколько *Theropithecus* рядом). Однако в целом дерево сильно перемешано: например *Phocoena* (дельфин) появляется рядом с грызунами, *Homo sapiens* не объединён с остальными приматами в чёткий кластер. Получаются биологически некорректные группировки.

NJ-дерево: Похожая проблема. *Ornithorhynchus* (утконос — монотрема, базальное млекопитающее) оказывается в самом верху без специального выделения как аутгруппы. Виды *Phocoena* снова разбросаны. Однако некоторые кластеры воспроизводятся, например группа *Urocyon* + *Mandrillus* + *Theropithecus*.

UPGMA-дерево: Топологически наиболее неправдоподобное. Например, *Ictidomys* (земляная белка) и *Condylura* (звездонос — крот) объединены с bootstrap 60, что биологически странно.

Почему деревья получились «неправильными»? Это связано с природой бета-актина. Он чрезвычайно консервативен: у всех 100 млекопитающих белок имеет длину 375 аминокислот и очень мало различается. Когда все последовательности

почти одинаковы, случайный шум начинает доминировать над филогенетическим сигналом, и дерево получается статистически слабым. Именно это объясняет низкие значения bootstrap на большинстве узлов.

Улучшение пайплайна анализа

Для получения более точных результатов рекомендуется:

- Заменить *ACTB* на более переменные маркеры (например, *CYTb* или *RAG1*), которые содержат больше информативных сайтов.
- Удалить паралогичные и дублирующиеся последовательности одного вида.
- Рассмотреть больше генов.